

从零训练迷你扩散模型 (MNIST DDPM)

实验报告

1 方法简述

1.1 前向加噪过程

采用线性噪声调度，噪声系数 β_t 从 $1e-4$ 线性增长至 0.02 ，总步数 $T=1000$ 。累积乘积 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ 。

一步加噪公式：

$$q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I)$$

1.2 去噪网络

小型 U-Net 架构：

- 3 级下采样 (通道 $32 \rightarrow 64 \rightarrow 128$)，每级含残差块
- 瓶颈层含自注意力 (Self-Attention)
- 3 级上采样，跳跃连接
- 正弦时间嵌入 (Sinusoidal Time Embedding) + GroupNorm + SiLU
- 参数量约 **1.69M** (满足 $\leq 5M$ 要求)

训练目标：最小化 MSE 损失

$$\mathcal{L} = \mathbb{E}_{x_0, \epsilon, t} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$$

1.3 反向采样

DDPM Ancestral Sampling：从纯噪声 $x_T \sim N(0, I)$ 逐步去噪至 x_0 。对非连续时间步使用 DDIM ($\eta=1$) 广义后验分布，保证较少步数下的采样质量。

DDIM 加速采样 (选做加分)：确定性采样 ($\eta=0$)，50 步即可生成高质量样本。


1.4 实验设置

项目	参数
数据集	MNIST (60,000 张 28×28 灰度图)
训练轮数	8 epochs
批大小	128
优化器	AdamW + CosineAnnealingLR
学习率	2e-4
硬件	CPU (20 核, 16 线程并行)
进度条	tqdm
Checkpoint	每 epoch 保存 latest.pth + epoch_N.pth

每 epoch 约 10-11 分钟 (CPU) , 总训练时间约 85 分钟。


2 实验结果

2.1 前向加噪可视化



从 $t=0$ 到 $t=999$, 图像逐步被高斯噪声淹没 , 验证了前向过程 $q(x_t|x_0)$ 的正确性。

2.2 训练损失曲线



损失在前 3 个 epoch 内从约 0.09 降至约 0.03，此后趋于平稳，表明模型已有效学习去噪映射。


2.3 生成样本网格 (8×8, DDPM 1000 步)



模型成功生成可辨识的 MNIST 手写数字，风格多样且无明显模式坍塌。

3 采样步数对比分析

3.1 对比图



3.2 耗时与质量对比

方法	步数	耗时(s)	质量
DDPM	1000	256.16	优秀
DDPM	200	54.11	良好
DDPM	50	12.47	一般
DDIM	50	12.34	优秀

3.3 分析

- 步数减少使得采样耗时近似线性下降（1000→50 步约 20 倍加速）。
- DDPM 在 200 步时质量已有所下降，50 步时出现明显模糊。
- DDIM 50 步 ($\eta=0$) 凭借确定性映射路径，在极少的步数下仍保持较高的生成质量。
- 综合来看，DDIM 50 步在质量与速度间取得最佳平衡。

4 遇到的问题与解决

问题	原因	解决方案
GroupNorm 通道数不整除	输入通道 <code>in_ch=1</code> ，无法用 8 组	使用 <code>min(8, in_ch)</code> 作为 group 数
非连续时间步采样退化为噪声	原始后验方差公式仅适用于相邻步	改用 DDIM ($\eta=1$) 广义后验分布

问题	原因	解决方案
CPU 训练慢	无 GPU 可用	减少 epochs 至 8，启用 16 线程并行
